

Análisis Exploratorio de Datos en R: Dinámicas Salariales en Ciencia de Datos e Inteligencia Artificial

Informe de consultoría — dataset `ds_salaries.csv`

Consultoría Analítica de Talento Humano

21 de September de 2026

1 Actividad 1: Carga, Auditoría y Tipificación Estadística

1.1 Dimensiones, estructura y calidad de los datos

El conjunto de datos `ds_salaries.csv` contiene **3755** observaciones (registros de profesionales) y **11** atributos. La Tabla 1 resume los tipos de variable tal como fueron importados por R.

Table 1: Tabla 1. Variables del dataset y tipo asignado por R

Variable	Tipo en R
<code>work_year</code>	<code>integer</code>
<code>experience_level</code>	<code>character</code>
<code>employment_type</code>	<code>character</code>
<code>job_title</code>	<code>character</code>
<code>salary</code>	<code>integer</code>
<code>salary_currency</code>	<code>character</code>
<code>salary_in_usd</code>	<code>integer</code>
<code>employee_residence</code>	<code>character</code>
<code>remote_ratio</code>	<code>integer</code>
<code>company_location</code>	<code>character</code>
<code>company_size</code>	<code>character</code>

Interpretación. El dataset combina variables numéricas (`work_year`, `salary`, `salary_in_usd`, `remote_ratio`) con variables de texto (`experience_level`, `employment_type`, `job_title`, `salary_currency`, `employee_residence`, `company_location`, `company_size`), que en R se importan por defecto como tipo `character` aunque conceptualmente corresponden a variables categóricas. Esta distinción es relevante porque, para el análisis estadístico, dichas columnas deberán tratarse explícitamente como factores.

1.2 Valores ausentes

Table 2: Tabla 2. Conteo de valores ausentes (NA) por columna

Variable	Valores ausentes (NA)
<code>work_year</code>	0
<code>experience_level</code>	0
<code>employment_type</code>	0
<code>job_title</code>	0
<code>salary</code>	0
<code>salary_currency</code>	0
<code>salary_in_usd</code>	0

Variable	Valores ausentes (NA)
employee_residence	0
remote_ratio	0
company_location	0
company_size	0

Interpretación. Ninguna de las 11 columnas presenta valores ausentes (NA = 0 en todos los casos). Esto indica que el conjunto de datos está completo en términos de registro, por lo que no es necesario aplicar técnicas de imputación o eliminación de observaciones por falta de información antes de continuar con el análisis. Esta completitud favorece la confiabilidad de los estadísticos descriptivos que se calcularán en las secciones siguientes, ya que no existe riesgo de sesgo por datos faltantes.

1.3 Registros duplicados

Se identificaron **1171** filas exactamente duplicadas (aproximadamente 31.2% del total), mediante `sum(duplicated(datos))`.

Análisis conceptual. Una fila duplicada en este conjunto de datos **no constituye necesariamente un error de captura o un defecto de calidad**. El dataset no incluye un identificador único de empleado; registra combinaciones de atributos laborales (año, nivel de experiencia, tipo de contrato, cargo, salario, moneda, país de residencia, modalidad remota, país de la empresa y tamaño de la empresa). Es perfectamente plausible que **dos o más profesionales distintos** compartan exactamente el mismo perfil —por ejemplo, dos “Data Scientist” Senior, tiempo completo, en Estados Unidos, con el mismo salario reportado y el mismo tamaño de empresa—, generando filas idénticas sin que exista redundancia de captura. Por esta razón, la eliminación automática de duplicados no es recomendable en este contexto: podría eliminar observaciones legítimas y sesgar las distribuciones salariales, en especial las de los grupos con menor tamaño muestral (por ejemplo, EX). En este informe los registros duplicados se **conservan**, dado que representan información potencialmente válida sobre la estructura del mercado laboral y no evidencia contundente de error.

1.4 Clasificación formal de variables

Table 3: Tabla 3. Clasificación de variables por tipo y escala de medición

Variable	Tipo	Escala
experience_level	Cualitativa	Ordinal
company_size	Cualitativa	Ordinal
salary_in_usd	Cuantitativa	De razón (continua)
remote_ratio	Cuantitativa discreta / Cualitativa ordinal (según objetivo)	De razón discreta / Ordinal

- **experience_level:** variable **cualitativa ordinal**. Sus categorías (EN, MI, SE, EX) representan niveles jerárquicos crecientes de experiencia profesional (Junior → Intermedio → Senior → Ejecutivo). Existe un orden natural entre las categorías, pero las distancias entre niveles no son necesariamente iguales ni cuantificables, por lo que no puede tratarse como variable numérica.
- **company_size:** variable **cualitativa ordinal**. Las categorías S, M y L corresponden a rangos crecientes de tamaño de plantilla (< 50, 50–250, > 250 empleados). Aunque el criterio de clasificación subyacente es numérico (número de empleados), la variable reportada en el dataset es una categoría ordenada, no el conteo exacto.
- **salary_in_usd:** variable **cuantitativa continua de razón**. Representa una magnitud monetaria estandarizada en dólares, admite todas las operaciones aritméticas (sumas, promedios, razones) y posee un cero absoluto con sentido (ausencia de ingreso). Es la variable central del análisis de tendencia central, dispersión y forma.
- **remote_ratio:** variable con doble lectura posible, que debe resolverse según el objetivo del análisis:
 - Como **variable cuantitativa discreta**, toma únicamente los valores 0, 50 y 100, que podrían interpretarse como puntos en una escala numérica de porcentaje de trabajo remoto. Sin embargo, no existen valores intermedios observados (por ejemplo 25 o 75), por lo que tratarla como continua no está respaldado por los datos, y el promedio de estos tres valores no tiene una interpretación operativa directa (un “58.3% remoto promedio” no describe un esquema real de trabajo).

- Como **variable categórica ordinal**, los tres valores representan grados cualitativos de modalidad laboral: 0 = presencial, 50 = híbrido, 100 = remoto total. Bajo esta lectura tiene sentido ordenar las categorías, pero no promediarlas.

Para los propósitos de este informe —caracterizar **esquemas** de trabajo remoto y compararlos frente a otras variables cualitativas— se adopta la **interpretación ordinal/categórica**, ya que el objetivo del análisis (Actividad 2 y discusión general) es describir la distribución de modalidades de trabajo, no calcular un promedio continuo de “grado de remotidad”.

1.5 Evaluación general de calidad

En síntesis, el conjunto de datos presenta una calidad estructural adecuada para el análisis exploratorio: no existen valores ausentes que exijan imputación, y aunque existe un número considerable de filas duplicadas, estas se interpretan como coincidencias plausibles de perfil laboral y no como errores de recolección. De haberse decidido eliminarlas sin este análisis conceptual previo, se habría corrido el riesgo de descartar observaciones válidas y de introducir un sesgo de subrepresentación en los grupos de experiencia con menor tamaño muestral (**EN**, **EX**), afectando la precisión de las medidas de tendencia central y dispersión que se calculan en la Actividad 3.

2 Actividad 2: Tablas de Frecuencias y Visualización Cualitativa — Tamaño de Empresa

Table 4: Tabla 4. Distribucion de frecuencias del tamano de empresa
(S = Pequena, M = Mediana, L = Grande)

Categoría	Frecuencia absoluta	Frecuencia relativa	Frecuencia porcentual
S	148	0.0394141	3.9%
M	3153	0.8396804	84.0%
L	454	0.1209055	12.1%




Figure 1: Figura 1. Distribución de registros por tamaño de empresa

Interpretación. La categoría **M (empresa mediana)** concentra la mayor cantidad de registros (84.0% de la muestra), constituyendo la **moda** de la variable `company_size`. En términos de mercado laboral, esto sugiere que, **dentro de esta muestra**, la contratación de perfiles de Ciencia de Datos e IA está fuertemente concentrada en organizaciones de tamaño intermedio (50–250 empleados), posiblemente empresas tecnológicas en fase de escalamiento que ya cuentan con

equipos de datos estructurados pero no operan con la magnitud de una gran corporación. Las empresas pequeñas (S) representan la categoría menos frecuente. Es importante distinguir entre la **frecuencia observada en esta muestra** —que refleja el sesgo de las fuentes que alimentaron el dataset— y una afirmación general sobre la totalidad del mercado laboral mundial, la cual no puede sostenerse únicamente con esta evidencia.

3 Actividad 3: Medidas de Tendencia Central, Dispersión y Forma

3.1 Estadísticos por nivel de experiencia

Table 5: Tabla 5. Estadísticos descriptivos del salario en USD por nivel de experiencia

Nivel	n	Media	Mediana	Varianza	Desv. Estándar	IQR	Mínimo	Máximo
EN	320	78,546	70,000	2,727,494,944	52,225	70,009	5,409	300,000
MI	805	104,526	100,000	2,958,020,294	54,388	68,163	5,132	450,000
SE	2516	153,051	146,000	3,237,184,852	56,896	70,900	8,000	423,834
EX	114	194,931	196,000	4,993,108,303	70,662	94,000	15,000	416,000

Interpretación. El grupo **EX** presenta el mayor salario promedio y también la mayor mediana, lo cual es consistente con la jerarquía profesional esperada: a mayor experiencia y responsabilidad, mayor remuneración. Los cuatro grupos muestran una progresión creciente y monótona de media y mediana desde **EN** hasta **EX**. El grupo **EX** presenta la mayor dispersión absoluta (desviación estándar), lo que indica una mayor heterogeneidad salarial dentro de ese nivel —posiblemente asociada a diferencias de especialización, ubicación geográfica o tipo de empresa entre perfiles ejecutivos—. En todos los grupos la media es superior a la mediana, lo cual es un primer indicio de **asimetría positiva** (cola derecha más larga, producto de salarios excepcionalmente altos que “jalan” el promedio hacia arriba sin desplazar igual la mediana). Estas lecturas deben entenderse como **posibles explicaciones o hipótesis** sobre la estructura del mercado laboral de datos, y no como relaciones causales demostradas por el conjunto de datos: el dataset no permite establecer, por ejemplo, que la experiencia *cause* directamente el incremento salarial, solo que ambas variables están asociadas en esta muestra.

3.2 Análisis de asimetría — Nivel Senior (SE)

Para el nivel Senior: media = 153,051 USD, mediana = 146,000 USD, coeficiente de asimetría (Fisher-Pearson) = 0.563.

Interpretación. La media (153,051) es superior a la mediana (146,000), y el coeficiente de asimetría es positivo (0.563), lo que en conjunto constituye evidencia de una **distribución con asimetría positiva (a la derecha)** para los salarios del grupo Senior. Esto significa que, aunque la mayoría de los profesionales Senior se agrupan en un rango salarial moderado, existe un subconjunto de observaciones con remuneraciones considerablemente más altas que alargan la cola derecha de la distribución y elevan el promedio por encima del valor típico (mediana). Una posible explicación —plantada como **hipótesis**, no como relación causal— es que esta asimetría podría estar asociada con diferencias de cargo dentro de la misma etiqueta “Senior” (por ejemplo, “Senior Data Scientist” frente a “Staff/Principal” en la práctica), con la especialización técnica, con el mercado geográfico de la empresa contratante, o con compensaciones excepcionalmente altas en un número reducido de casos (posibles valores atípicos, analizados en la sección de boxplots).

3.3 Coeficiente de Variación

Table 6: Tabla 6. Coeficiente de Variación por nivel de experiencia

Nivel	Media (USD)	Desv. Est. (USD)	CV (%)
EN	78,546.28	52,225.42	66.49
MI	104,525.94	54,387.69	52.03
SE	153,051.07	56,896.26	37.17
EX	194,930.93	70,661.93	36.25

Interpretación. El nivel **EN** presenta el mayor Coeficiente de Variación, es decir, la **mayor variabilidad relativa** de ingresos respecto a su propio promedio, a pesar de que en términos absolutos otros grupos puedan tener una desviación estándar en dólares numéricamente mayor o similar. Esto ilustra por qué **la desviación estándar absoluta, por sí sola, no es una medida adecuada para comparar la dispersión entre grupos cuyo nivel salarial promedio difiere sustancialmente**: un mismo número de dólares de desviación representa una proporción muy distinta del ingreso típico según el grupo. El CV, al normalizar la desviación estándar por la media, permite una comparación justa de la variabilidad relativa entre EN, MI, SE y EX, evidenciando que los niveles de menor experiencia tienden a mostrar mayor heterogeneidad relativa en sus ingresos que los niveles más senior, cuyos salarios están más “acotados” proporcionalmente en torno a su propio promedio.

3.4 Diagrama de cajas comparativo




Figure 2: Figura 2. Boxplot comparativo del salario en USD por nivel de experiencia

Interpretación. El boxplot confirma la progresión ascendente de las **medianas** (línea central de cada caja) desde EN hasta EX. La **amplitud de las cajas** (rango intercuartílico) es más estrecha en EN y se amplía progresivamente hacia SE y, sobre todo, EX, lo que indica mayor dispersión absoluta del 50% central de los datos en los niveles más altos. Se observan **valores atípicos** (puntos fuera de los bigotes) en varios de los grupos, principalmente en la cola superior, consistentes con salarios excepcionalmente altos que ya se habían identificado en el análisis de asimetría. Las diferencias entre grupos son claras y consistentes: no hay solapamiento sustancial entre las cajas de EN y EX, lo que refuerza la asociación entre nivel de experiencia y nivel salarial observada en esta muestra, sin que ello implique una relación determinística para un individuo en particular.

3.5 Gráfico de cuantiles normales (QQ-Plot) — Nivel Senior

Interpretación. En un QQ-Plot, si los datos siguieran una distribución aproximadamente normal, los puntos se alinearían sobre la recta de referencia. En este caso, los puntos se ajustan razonablemente a la recta en la región central de la distribución, pero se **desvían hacia arriba en la cola derecha** (valores muestrales superiores a los teóricos para los cuantiles más altos), lo cual es consistente con la asimetría positiva ya detectada mediante el coeficiente de asimetría. Esta desviación visual confirma que la distribución de salarios del grupo Senior **no es exactamente normal**: presenta una cola derecha más pesada de lo que predeciría una distribución Normal, coherente con la presencia de un subconjunto de compensaciones excepcionalmente altas.

4 Actividad 4: Distribución por Intervalos y Análisis de Umbral Salarial

4.1 Cuartiles y percentil 90




Figure 3: Figura 3. QQ-Plot del salario en USD para el nivel Senior (SE)

Table 7: Tabla 7. Cuantiles y percentil 90 del salario en USD (muestra completa)

	Estadístico	Valor (USD)
25%	Q1 (25%)	95,000
50%	Q2 / Mediana (50%)	135,000
75%	Q3 (75%)	175,000
90%	P90 (90%)	219,000

Interpretación. El 25% de los profesionales de la muestra gana 95,000 USD o menos anuales, mientras que el 10% superior (por encima de P90) supera los 219,000 USD. La distancia entre Q3 y P90 es notablemente mayor que la distancia entre Q1 y Q2, lo que anticipa una cola derecha extendida en la distribución global de salarios, tal como se confirmará en el histograma siguiente.

4.2 Tabla de frecuencias por intervalos e histograma

Table 8: Tabla 8. Distribucion de frecuencias por intervalos del salario en USD

Intervalo (USD)	Frecuencia absoluta	Frecuencia relativa	Porcentaje
5,000 - 69,000	519	0.1382157	13.8%
69,000 - 133,000	1317	0.3507324	35.1%
133,000 - 197,000	1304	0.3472703	34.7%
197,000 - 261,000	503	0.1339547	13.4%
261,000 - 325,000	90	0.0239680	2.4%
325,000 - 389,000	15	0.0039947	0.4%
389,000 - 453,000	7	0.0018642	0.2%



(137,570 USD) sea superior a la mediana global (135,000 USD). Desde una perspectiva de mercado, esto sugiere que la mayoría de los profesionales del sector se concentra en un rango salarial “estándar”, mientras que un grupo minoritario —probablemente perfiles muy senior, altamente especializados o ubicados en mercados de compensación elevada— accede a remuneraciones sustancialmente superiores al resto.

4.3 Umbral salarial junior: 80,000 USD

De los **320** profesionales de nivel Entry-level (EN) en la muestra, **138 (43.1%)** alcanzan o superan el umbral de 80,000 USD anuales definido por la firma consultora como “salario junior altamente competitivo”.

Interpretación. Dentro de esta muestra, alcanzar un salario junior de al menos 80,000 USD es una situación **relativamente minoritaria pero no marginal**: representa poco menos de la mitad de los profesionales Entry-level observados. Esto sugiere que, si bien existe un grupo considerable de profesionales junior bien remunerados, la mayoría de este segmento se ubica por debajo de dicho umbral. Esta conclusión debe limitarse estrictamente a la evidencia disponible en el conjunto de datos: el dataset no es necesariamente representativo de todo el mercado laboral global de Ciencia de Datos e IA (puede sobre-representar ciertos países, empresas o plataformas de origen de los datos), por lo que esta cifra no debe generalizarse como un hecho universal del mercado laboral mundial, sino como un hallazgo descriptivo específico de esta muestra.

5 Actividad 5: Conclusiones Ejecutivas

Síntesis gerencial. El análisis evidencia que la remuneración en el sector de Ciencia de Datos e Inteligencia Artificial sigue una distribución con **asimetría positiva**: la mayoría de los profesionales se agrupa en un rango salarial moderado, mientras un segmento minoritario percibe compensaciones considerablemente más altas, elevando el promedio por encima del valor típico. El **nivel de experiencia** emerge como el factor descriptivo más asociado a la remuneración: los salarios promedio y medianos crecen de forma sostenida desde perfiles junior hasta ejecutivos, aunque la variabilidad relativa (coeficiente de variación) es mayor en los niveles menos senior, lo que sugiere trayectorias salariales más heterogéneas al inicio de la carrera. Para una firma de consultoría en talento humano, esto implica que las estrategias de compensación **no deberían basarse únicamente en promedios**, sino considerar la dispersión y la posible presencia de valores atípicos dentro de cada nivel al diseñar bandas salariales competitivas. Asimismo, el hecho de que solo una fracción de los perfiles junior supere el umbral de alta competitividad salarial sugiere una oportunidad de asesoría diferenciada para organizaciones que buscan atraer talento temprano con ofertas por encima del promedio del segmento. Estas lecturas se presentan como hallazgos descriptivos de la muestra analizada y como hipótesis orientadoras para estudios posteriores, no como relaciones causales comprobadas.

6 Actividad 6: Abstract

Abstract. This report presents an exploratory data analysis (EDA) of the `ds_salaries.csv` dataset, which contains 3755 records describing annual compensation and working conditions for Data Science and Artificial Intelligence professionals, including experience level, employment type, remote-work ratio, company size, and salary standardized in US dollars. The purpose of the analysis was to audit data quality, characterize the distribution of `salary_in_usd`, compare compensation across experience-level groups, and describe the distribution of company sizes and remote-work schemes, adopting the perspective of an analytical consultant advising multinational organizations on compensation strategy. The study applied univariate descriptive techniques in R, including frequency tables, measures of central tendency, dispersion and shape (mean, median, variance, standard deviation, interquartile range, coefficient of variation, and skewness), boxplots, a normal Q-Q plot, and an interval-based frequency distribution with histogram. Results show that the dataset contains no missing values but a substantial number of exact duplicate rows, interpreted as plausible coincidences of professional profile rather than collection errors. Salaries increase monotonically with experience level, from Entry-level to Executive, while relative variability (coefficient of variation) is highest among less senior groups. The overall salary distribution, and particularly the Senior subgroup, exhibits positive skewness, confirmed jointly by the mean-median comparison, the skewness coefficient, and the Q-Q plot. Only a minority of Entry-level professionals reach the 80,000 USD “highly competitive junior salary” threshold defined for this exercise. The general conclusion is that experience level is descriptively associated with higher and more concentrated compensation, while junior and mid-level roles show greater relative salary heterogeneity, insights that should inform, but not by themselves determine, compensation benchmarking decisions for this sample.

7 Anexo Técnico: Código Fuente Completo

El código R completo utilizado para generar este informe se presenta a continuación con fines de reproducibilidad.

```
knitr::opts_chunk$set(
  echo = FALSE, warning = FALSE, message = FALSE,
  fig.align = "center", fig.width = 5.6, fig.height = 3.2,
  dev = "cairo_pdf"
)

library(dplyr)
library(ggplot2)
library(knitr)
library(e1071)
library(tidyr)
library(scales)

datos <- read.csv("data/ds_salaries.csv", stringsAsFactors = FALSE)
n_obs <- nrow(datos)
n_vars <- ncol(datos)
na_por_col <- colSums(is.na(datos))
n_dup <- sum(duplicated(datos))
resumen_vars <- data.frame(
  Variable = names(datos),
  Tipo_R = sapply(datos, class),
  row.names = NULL
)
kable(resumen_vars, col.names = c("Variable", "Tipo en R"),
  caption = "Tabla 1. Variables del dataset y tipo asignado por R")
kable(data.frame(Variable = names(na_por_col), NA_count = as.integer(na_por_col)),
  col.names = c("Variable", "Valores ausentes (NA)"),
  caption = "Tabla 2. Conteo de valores ausentes (NA) por columna")
tabla_clasif <- data.frame(
  Variable = c("experience_level", "company_size", "salary_in_usd", "remote_ratio"),
  Tipo = c("Cualitativa", "Cualitativa", "Cuantitativa", "Cuantitativa discreta / Cualitativa ordinal (según
  ↪ objetivo)"),
  Escala = c("Ordinal", "Ordinal", "De razón (continua)", "De razón discreta / Ordinal"),
  row.names = NULL
)
kable(tabla_clasif, caption = "Tabla 3. Clasificación de variables por tipo y escala de medición")
tabla_size <- datos %>%
  count(company_size) %>%
  mutate(
    company_size = factor(company_size, levels = c("S", "M", "L")),
    Frec_relativa = n / sum(n),
    Frec_porcentual = percent(Frec_relativa, accuracy = 0.1)
  ) %>%
  arrange(company_size) %>%
  rename(Categoria = company_size, Frec_absoluta = n)

kable(tabla_size, col.names = c("Categoría", "Frecuencia absoluta", "Frecuencia relativa", "Frecuencia
  ↪ porcentual"),
  caption = "Tabla 4. Distribucion de frecuencias del tamaño de empresa (S = Pequeña, M = Mediana, L =
  ↪ Grande)")
ggplot(datos %>% mutate(company_size = factor(company_size, levels = c("S", "M", "L"))),
  aes(x = company_size, fill = company_size)) +
  geom_bar() +
  geom_text(stat = "count", aes(label = after_stat(count)), vjust = -0.4, size = 3.3) +
  scale_fill_manual(values = c("S" = "#8DA0CB", "M" = "#66C2A5", "L" = "#FC8D62")) +
  labs(x = "Tamaño de la empresa", y = "Número de registros",
  title = "Profesionales de datos por tamaño de empresa") +
  theme_minimal(base_size = 11) +
  theme(legend.position = "none")
```

```

moda_size <- tabla_size$Categoria[which.max(tabla_size$Frec_absoluta)]
pct_moda <- tabla_size$Frec_porcentual[which.max(tabla_size$Frec_absoluta)]
niveles <- c("EN", "MI", "SE", "EX")
etiquetas <- c(EN = "Entry-level (EN)", MI = "Mid-level (MI)", SE = "Senior (SE)", EX = "Executive (EX)")

tabla_exp <- datos %>%
  filter(experience_level %in% niveles) %>%
  group_by(experience_level) %>%
  summarise(
    n = n(),
    Media = mean(salary_in_usd),
    Mediana = median(salary_in_usd),
    Varianza = var(salary_in_usd),
    Desv_Est = sd(salary_in_usd),
    IQR = IQR(salary_in_usd),
    Minimo = min(salary_in_usd),
    Maximo = max(salary_in_usd)
  ) %>%
  mutate(experience_level = factor(experience_level, levels = niveles)) %>%
  arrange(experience_level)

tabla_exp_fmt <- tabla_exp %>%
  mutate(across(c(Media, Mediana, Varianza, Desv_Est, IQR, Minimo, Maximo),
    ~ comma(round(.x, 0))))

kable(tabla_exp_fmt,
  col.names = c("Nivel", "n", "Media", "Mediana", "Varianza", "Desv. Estándar", "IQR", "Mínimo",
    ↪ "Máximo"),
  caption = "Tabla 5. Estadísticos descriptivos del salario en USD por nivel de experiencia")

gpo_mayor_media <- tabla_exp$experience_level[which.max(tabla_exp$Media)]
gpo_mayor_mediana <- tabla_exp$experience_level[which.max(tabla_exp$Mediana)]
gpo_mayor_sd <- tabla_exp$experience_level[which.max(tabla_exp$Desv_Est)]
gpo_menor_sd <- tabla_exp$experience_level[which.min(tabla_exp$Desv_Est)]
se_sal <- datos$salary_in_usd[datos$experience_level == "SE"]
media_se <- mean(se_sal)
mediana_se <- median(se_sal)
skew_se <- skewness(se_sal, type = 2)
tabla_cv <- tabla_exp %>%
  mutate(CV = round(Desv_Est / Media * 100, 2)) %>%
  select(experience_level, Media, Desv_Est, CV)

kable(tabla_cv, col.names = c("Nivel", "Media (USD)", "Desv. Est. (USD)", "CV (%)" ),
  caption = "Tabla 6. Coeficiente de Variación por nivel de experiencia",
  format.args = list(big.mark = ","))

gpo_mayor_cv <- tabla_cv$experience_level[which.max(tabla_cv$CV)]
ggplot(datos %>% mutate(experience_level = factor(experience_level, levels = niveles)),
  aes(x = experience_level, y = salary_in_usd, fill = experience_level)) +
  geom_boxplot(outlier.color = "firebrick", outlier.alpha = 0.5, outlier.size = 1.2) +
  scale_y_continuous(labels = comma) +
  scale_fill_brewer(palette = "Blues") +
  labs(x = "Nivel de experiencia", y = "Salario anual (USD)",
  title = "Salario en USD según nivel de experiencia") +
  theme_minimal(base_size = 11) +
  theme(legend.position = "none")
ggplot(data.frame(salario = se_sal), aes(sample = salario)) +
  stat_qq(color = "#3182BD", alpha = 0.6, size = 1.1) +
  stat_qq_line(color = "firebrick", linewidth = 0.7) +
  labs(x = "Cuantiles teóricos (Normal)", y = "Cuantiles muestrales (USD)",
  title = "QQ-Plot: salario Senior (SE) vs. distribución Normal") +
  theme_minimal(base_size = 11)
q <- quantile(datos$salary_in_usd, probs = c(0.25, 0.5, 0.75, 0.90))

```

```

kable(data.frame(Estadistico = c("Q1 (25%)", "Q2 / Mediana (50%)", "Q3 (75%)", "P90 (90%)"),
  Valor_USD = comma(round(q,0))),
  col.names = c("Estadístico", "Valor (USD)"),
  caption = "Tabla 7. Cuartiles y percentil 90 del salario en USD (muestra completa)")

n_clases <- 7
rango <- range(datos$salary_in_usd)
amplitud <- ceiling(diff(rango) / n_clases / 1000) * 1000
limite_inf <- floor(rango[1] / 1000) * 1000
cortes <- seq(limite_inf, limite_inf + amplitud * n_clases, by = amplitud)

etiquetas_int <- paste0(comma(head(cortes, -1)), " - ", comma(tail(cortes, -1)))
datos$intervalo_salario <- cut(datos$salary_in_usd, breaks = cortes, include.lowest = TRUE,
  right = TRUE, labels = etiquetas_int)

tabla_int <- datos %>%
  count(intervalo_salario) %>%
  mutate(
    Frec_relativa = n / sum(n),
    Porcentaje = percent(Frec_relativa, accuracy = 0.1)
  ) %>%
  rename(Intervalo = intervalo_salario, Frec_absoluta = n)

kable(tabla_int, col.names = c("Intervalo (USD)", "Frecuencia absoluta", "Frecuencia relativa",
  → "Porcentaje"),
  caption = "Tabla 8. Distribucion de frecuencias por intervalos del salario en USD")

ggplot(datos, aes(x = salary_in_usd)) +
  geom_histogram(breaks = cortes, fill = "#4292C6", color = "white", linewidth = 0.3) +
  scale_x_continuous(breaks = cortes, labels = comma) +
  labs(x = "Salario anual (USD)", y = "Frecuencia absoluta",
  title = "Histograma del salario anual en USD") +
  theme_minimal(base_size = 10) +
  theme(axis.text.x = element_text(angle = 40, hjust = 1))

en_df <- datos %>% filter(experience_level == "EN")
n_en <- nrow(en_df)
n_en_80k <- sum(en_df$salary_in_usd >= 80000)
pct_en_80k <- n_en_80k / n_en

```