

Taller de Análisis Exploratorio de Datos en R

Salarios en Ciencia de Datos e Inteligencia Artificial (ds_salaries.csv)

Leandro Rojas – ID: 883963

21 de September de 2026

Este informe presenta un análisis exploratorio del conjunto de datos `ds_salaries.csv`, con el objetivo de entender cómo se comportan los salarios y las condiciones laborales en el área de Ciencia de Datos e Inteligencia Artificial.

1 Actividad 1: Carga, Auditoría y Tipificación Estadística

1.1 Dimensiones, estructura y calidad de los datos

El archivo `ds_salaries.csv` tiene **3755** filas (cada fila es un profesional) y **11** columnas. En la Tabla 1 se muestra el tipo que R le asignó a cada columna al importarla.

Tabla 1: Variables del dataset y tipo asignado por R

Variable	Tipo en R
work_year	integer
experience_level	character
employment_type	character
job_title	character
salary	integer
salary_currency	character
salary_in_usd	integer
employee_residence	character
remote_ratio	integer
company_location	character
company_size	character

Interpretación. Hay columnas numéricas (`work_year`, `salary`, `salary_in_usd`, `remote_ratio`) y columnas de texto (`experience_level`, `employment_type`, `job_title`, `salary_currency`, `employee_residence`, `company_location`, `company_size`). R importa el texto como tipo `character`, aunque en realidad varias de esas columnas son categorías (por ejemplo, el nivel de experiencia o el tamaño de la empresa). Es importante tenerlo claro porque, si más adelante se quiere trabajar con esas columnas como categorías ordenadas, hay que convertirlas explícitamente a factor.

1.2 Valores ausentes

Tabla 2: Conteo de valores ausentes (NA) por columna

Variable	Valores ausentes (NA)
work_year	0
experience_level	0
employment_type	0
job_title	0
salary	0
salary_currency	0
salary_in_usd	0
employee_residence	0
remote_ratio	0
company_location	0
company_size	0

Interpretación. Ninguna columna tiene valores vacíos (todas dan 0 en NA). Esto significa que no es necesario decidir qué hacer con datos faltantes (por ejemplo, borrarlos o rellenarlos): se puede trabajar con el archivo completo tal como está.

1.3 Registros duplicados

Con la función `sum(duplicated(datos))` se identificaron **1171** filas que están repetidas exactamente (cerca del 31.2% del total de filas).

¿Qué significa esto? Tener tantas filas repetidas podría parecer un error del archivo, pero no tiene que serlo. El dataset no tiene una columna de “ID” para cada persona; solo guarda características del empleo (año, nivel de experiencia, tipo de contrato, cargo, salario, moneda, país, modalidad de trabajo, tamaño de empresa, etc.). Por lo tanto, es posible que dos personas distintas tengan exactamente el mismo perfil laboral -por ejemplo, dos “Data Scientist” Senior de tiempo completo en Estados Unidos, con el mismo salario y el mismo tamaño de empresa- y eso generaría dos filas idénticas sin que exista ningún error de captura. Por esta razón se optó por **no eliminar** los duplicados: hacerlo implicaría el riesgo de perder información real, sobre todo en los grupos que ya tienen pocos datos (como EX).

1.4 Clasificación de variables

Tabla 3: Clasificación de variables por tipo y escala de medición

Variable	Tipo	Escala
experience_level	Cualitativa	Ordinal
company_size	Cualitativa	Ordinal
salary_in_usd	Cuantitativa	Continua (de razón)
remote_ratio	Cuantitativa discreta / Cualitativa ordinal (según el uso)	Discreta / Ordinal

- **experience_level:** es una variable **cualitativa ordinal**. Sus categorías (EN, MI, SE, EX) tienen un orden claro, de menos a más experiencia (Junior, Intermedio, Senior, Ejecutivo), pero no son números: no se puede decir que la distancia entre EN y MI sea “igual” a la distancia entre SE y EX.

- **company_size**: también es **cualitativa ordinal**. Las categorías S, M y L representan tamaños de empresa que van de menor a mayor (menos de 50, entre 50 y 250, más de 250 empleados), pero en el archivo aparecen como una letra, no como el número exacto de empleados.
- **salary_in_usd**: esta sí es una variable **cuantitativa continua**, de escala de razón. Es un valor en dólares con el cual se pueden hacer sumas, promedios y comparaciones, y tiene un cero que sí significa “sin ingreso”. Es la variable más importante de este trabajo porque sobre ella se calculan casi todos los análisis siguientes.
- **remote_ratio**: esta variable se puede leer de dos maneras distintas y depende de para qué se vaya a usar:
 - Como **variable cuantitativa discreta**, solo toma los valores 0, 50 y 100. El problema es que no existen valores intermedios (como 25 o 75), así que promediar estos números no dice mucho: un “58% remoto en promedio” no describe ninguna modalidad de trabajo real.
 - Como **variable categórica ordinal**, esos mismos tres valores representan tres modalidades de trabajo: 0 = presencial, 50 = híbrido, 100 = remoto total. Bajo esta lectura sí tiene sentido decir cuál modalidad es más común, pero no promediarlas.

En este informe se trata **remote_ratio** como **categórica/ordinal**, porque el objetivo es describir qué modalidad de trabajo es más frecuente, y no calcular un “porcentaje promedio de remotidad” que en la práctica no representa nada concreto.

1.5 ¿Cómo está la calidad de los datos en general?

En resumen, el archivo está bastante completo: no hay valores vacíos, así que no fue necesaria ninguna limpieza por ese lado. Sí hay bastantes filas duplicadas, pero, como se explicó antes, se conservan porque probablemente representan personas distintas con el mismo perfil laboral, y no un error de recolección. Eliminarlas sin este análisis previo habría implicado el riesgo de perder información válida, afectando sobre todo a los grupos con menos datos, como el de nivel Ejecutivo, y esto habría hecho menos confiables los cálculos de la Actividad 3.

2 Actividad 2: Tablas de Frecuencias y Visualización Cualitativa — Tamaño de Empresa

Tabla 4: Distribucion de frecuencias del tamano de empresa
(S = Pequena, M = Mediana, L = Grande)

Categoría	Frecuencia absoluta	Frecuencia relativa	Frecuencia porcentual
S	148	0.0394141	3.9%
M	3153	0.8396804	84.0%
L	454	0.1209055	12.1%




Figura 1: Distribución de registros por tamaño de empresa

Interpretación. La categoría **M (empresa mediana)** es la que más se repite, con 84.0% de los registros: esa es la **moda** de la variable `company_size`. Esto indica que, en esta muestra, la mayoría de los profesionales de datos trabajan en empresas medianas (entre 50 y 250 empleados), tal vez porque son empresas de tecnología que ya crecieron lo suficiente como para tener un equipo de datos, pero que todavía no son una gran corporación. Las empresas pequeñas (S) son las que menos aparecen. Aquí es importante tener cuidado: esto es lo que se observa **en esta muestra**, no necesariamente lo que pasa en todo el mercado laboral del mundo, porque no sabemos qué tan representativo es este conjunto de datos.

3 Actividad 3: Medidas de Tendencia Central, Dispersión y Forma

3.1 Estadísticos por nivel de experiencia

Tabla 5: Estadísticos descriptivos del salario en USD por nivel de experiencia

Nivel	n	Media	Mediana	Varianza	Desv. Estándar	IQR	Mínimo	Máximo
EN	320	78,546	70,000	2,727,494,944	52,225	70,009	5,409	300,000
MI	805	104,526	100,000	2,958,020,294	54,388	68,163	5,132	450,000
SE	2516	153,051	146,000	3,237,184,852	56,896	70,900	8,000	423,834
EX	114	194,931	196,000	4,993,108,303	70,662	94,000	15,000	416,000

Interpretación. El grupo **EX** es el que tiene el salario promedio más alto y también la mediana más alta. Tiene sentido: entre más experiencia y responsabilidad tiene un profesional, más gana. Se ve además que el promedio y la mediana van subiendo poco a poco desde **EN** hasta **EX**, sin saltos raros. El grupo **EX** es el que tiene la desviación estándar más alta, es decir, sus salarios son los que más varían entre sí; esto podría deberse a que dentro de “Ejecutivo” caben perfiles muy distintos (distintas industrias, países o tamaños de empresa). También se observa que en todos los grupos el promedio es más alto que la mediana, lo que suele ser una señal de que hay algunos salarios muy altos que “jalan” el promedio hacia arriba sin mover tanto a la mediana (a esto se le llama asimetría positiva, y se analiza con más detalle en la siguiente sección). Todo esto son observaciones sobre los datos, no pruebas de que la experiencia “cause” directamente un salario más alto; solo se puede afirmar que ambas variables están relacionadas en esta muestra.

3.2 Análisis de asimetría — Nivel Senior (SE)

Para el nivel Senior obtuve: media = 153,051 USD, mediana = 146,000 USD, y un coeficiente de asimetría de 0.563.

Interpretación. Como la media (153,051) es mayor que la mediana (146,000), y el coeficiente de asimetría es positivo, esto quiere decir que la distribución de salarios del nivel Senior tiene **asimetría positiva** (o “cola a la derecha”). En palabras simples: la mayoría de los Senior gana un salario más o menos parecido, pero hay un grupo más pequeño que gana bastante más que el resto, y esos salarios altos son los que suben el promedio. Como hipótesis (no como algo que los datos demuestren con certeza), esta diferencia podría deberse a que dentro de la etiqueta “Senior” hay cargos distintos (por ejemplo, un “Senior Data Scientist” no es lo mismo que un cargo tipo “Staff” o “Principal” aunque a veces se cuenten igual), a diferencias de país, o simplemente a que hay unos pocos salarios muy altos que se comportan como valores atípicos, algo que se revisa más adelante con el diagrama de cajas.

3.3 Coeficiente de Variación

Tabla 6: Coeficiente de Variación por nivel de experiencia

Nivel	Media (USD)	Desv. Est. (USD)	CV (%)
EN	78,546.28	52,225.42	66.49
MI	104,525.94	54,387.69	52.03
SE	153,051.07	56,896.26	37.17
EX	194,930.93	70,661.93	36.25

Interpretación. El nivel **EN** es el que tiene el Coeficiente de Variación más alto, es decir, sus salarios varían más **en proporción a su propio promedio**, aunque en dólares la desviación estándar de otros grupos sea parecida o incluso mayor. Esto ilustra un punto importante: comparar la desviación estándar en dólares entre grupos que ganan montos muy distintos puede ser engañoso, porque la misma cantidad de dólares de diferencia “pesa” distinto según cuánto gane el grupo en promedio. El Coeficiente de Variación soluciona esto porque compara la desviación estándar con el promedio de cada grupo, y con esa medida se ve que los niveles con menos experiencia tienen salarios más variables entre sí (en proporción), mientras que en los niveles más senior los salarios están un poco más “agrupados” alrededor de su propio promedio.

3.4 Diagrama de cajas comparativo




Figura 2: Boxplot comparativo del salario en USD por nivel de experiencia

Interpretación. En el gráfico se ve muy claro que la línea del medio de cada caja (la mediana) va subiendo desde EN hasta EX. También se nota que la caja (donde está el 50% central de los datos) es más angosta en EN y se va haciendo más ancha en SE y sobre todo en EX, lo que quiere decir que en los niveles más altos los salarios varían más entre sí. Hay varios puntos rojos fuera de los “bigotes” del gráfico, casi todos hacia arriba: esos son los valores atípicos, es decir, salarios muy por encima de lo normal para ese grupo, y coinciden con lo observado en el análisis de asimetría. Las cajas de EN y EX prácticamente no se cruzan, lo que confirma que en esta muestra sí hay una relación bastante clara entre nivel de experiencia y salario, aunque eso no significa que le vaya a pasar exactamente igual a cada persona en particular.

3.5 Gráfico de cuantiles normales (QQ-Plot) — Nivel Senior

Interpretación. Un QQ-Plot sirve para comparar los datos reales contra lo que se esperaría si siguieran una distribución Normal (la clásica “campana de Gauss”): si los puntos caen sobre la línea roja, la distribución se parece a una Normal. Aquí los puntos siguen bastante bien la línea en la parte de en medio, pero **se alejan hacia arriba en la parte derecha del gráfico**, es decir, para los salarios más altos. Esto confirma lo encontrado con el coeficiente de asimetría: los salarios del grupo Senior no siguen una distribución Normal perfecta, sino que tienen esa cola de valores altos que se sale de lo esperado.




Figura 3: QQ-Plot del salario en USD para el nivel Senior (SE)

4 Actividad 4: Distribución por Intervalos y Análisis de Umbral Salarial

4.1 Cuartiles y percentil 90

Tabla 7: Cuartiles y percentil 90 del salario en USD (muestra completa)

	Estadístico	Valor (USD)
25%	Q1 (25%)	95,000
50%	Q2 / Mediana (50%)	135,000
75%	Q3 (75%)	175,000
90%	P90 (90%)	219,000

Interpretación. El 25% de los profesionales de la muestra gana 95,000 USD al año o menos, mientras que el 10% que mejor gana (por encima del percentil 90) supera los 219,000 USD. La distancia entre Q3 y P90 es bastante más grande que la distancia entre Q1 y Q2, lo cual es una pista de que arriba hay salarios que se disparan bastante más que en la parte baja, algo que se confirma con el histograma de abajo.

4.2 Tabla de frecuencias por intervalos e histograma

Tabla 8: Distribucion de frecuencias por intervalos del salario en USD

Intervalo (USD)	Frecuencia absoluta	Frecuencia relativa	Porcentaje
5,000 - 69,000	519	0.1382157	13.8%
69,000 - 133,000	1317	0.3507324	35.1%
133,000 - 197,000	1304	0.3472703	34.7%

Intervalo (USD)	Frecuencia absoluta	Frecuencia relativa	Porcentaje
197,000 - 261,000	503	0.1339547	13.4%
261,000 - 325,000	90	0.0239680	2.4%
325,000 - 389,000	15	0.0039947	0.4%
389,000 - 453,000	7	0.0018642	0.2%




Figura 4: Histograma del salario en USD con límites de clase marcados

Interpretación. El histograma tiene una sola “joroba” (es unimodal) y se inclina hacia la izquierda, es decir, la mayoría de los salarios están en los intervalos bajos o medios, y a medida que el salario sube, cada vez hay menos personas en ese rango. Esto encaja con lo que ya se había visto en la Actividad 3 para el grupo Senior, y también con que el promedio general (137,570 USD) sea más alto que la mediana general (135,000 USD). En otras palabras, la mayoría de los profesionales de este sector gana un salario “normal” dentro de cierto rango, y solo un grupo más chico -tal vez los perfiles más senior, más especializados o de países donde se paga más- llega a salarios bastante más altos que el resto.

4.3 Umbral salarial junior: 80,000 USD

De los **320** profesionales de nivel Entry-level (EN) en la muestra, **138 (43.1%)** ganan 80,000 USD al año o más, que es el umbral que se definió como “salario junior altamente competitivo”.

Interpretación. Llegar a ese umbral de 80,000 USD siendo junior no es lo más común, pero tampoco es raro: es un poco menos de la mitad de los profesionales Entry-level de la muestra. Esto quiere decir que sí existe un grupo importante de juniors muy bien pagados, pero que la mayoría todavía está por debajo de ese número. Hay que tener cuidado de no sacar conclusiones demasiado grandes con este dato: el conjunto de datos puede tener más información de unos países o empresas que de otros, así que este resultado aplica a esta muestra y no se debería afirmar que representa a todo el mercado laboral mundial.

5 Actividad 5: Conclusiones Ejecutivas

En síntesis, el salario en el sector de Ciencia de Datos e Inteligencia Artificial no se reparte de forma pareja: la mayoría de los profesionales gana dentro de un rango más o menos parecido, pero hay un grupo más pequeño que gana bastante más y que hace que el promedio general se vea más alto de lo que realmente gana “la mayoría”. El nivel de experiencia parece ser el factor que más se relaciona con el salario: entre más experiencia tiene alguien, más tiende a ganar, y esto se repite de forma bastante constante desde los perfiles junior hasta los ejecutivos. Sin embargo, los niveles con menos experiencia son los que muestran mayor variación en sus salarios en proporción a lo que ganan, lo que sugiere que al inicio de la carrera hay más diferencias entre una persona y otra. Para una empresa que asesora en temas de talento humano, esto podría significar que no conviene fijar ofertas salariales mirando solo el promedio, sino tener en cuenta también qué tan dispersos están los salarios y si hay casos que se salen mucho de lo normal dentro de cada nivel. Estas son lecturas basadas únicamente en lo que se observó en esta muestra de datos, no conclusiones definitivas sobre causas ni sobre todo el mercado laboral.

6 Actividad 6: Abstract

Abstract. This report presents an exploratory data analysis (EDA) of the `ds_salaries.csv` dataset, which contains 3755 records about annual compensation and working conditions for Data Science and Artificial Intelligence professionals, including experience level, employment type, remote-work ratio, company size, and salary standardized in US dollars. The purpose of this analysis was to check the quality of the data, describe how salaries are distributed, compare compensation across experience-level groups, and describe how company size and remote-work categories are distributed. The analysis used basic descriptive statistics in R: frequency tables, mean, median, variance, standard deviation, interquartile range, coefficient of variation, skewness, boxplots, a normal Q-Q plot, and a frequency table by salary intervals with a histogram. Results show that the dataset has no missing values, but it does have many exact duplicate rows, which were kept because they can represent different people with the same job profile rather than data-entry errors. Salaries increase step by step with experience level, from Entry-level to Executive, while relative variability (measured with the coefficient of variation) is higher among less senior groups. The overall salary distribution, and especially the Senior group, shows positive skewness: most professionals earn a “typical” salary, while a smaller group earns noticeably more, which pulls the average above the median. Only a minority of Entry-level professionals reach the 80,000 USD threshold defined as a “highly competitive junior salary” in this exercise. As a general conclusion, experience level appears descriptively related to higher and slightly more concentrated salaries, while junior profiles show more relative variation in their pay. These findings are based only on this sample and should be read as exploratory, not as final or causal conclusions.